UNIVERZITET U BEOGRADU
ELEKTROTEHNIČKI FAKULTET



ANALIZA TRŽIŠTA BELE TEHNIKE U SRPSKIM INTERNET PRODAVNICAMA

Pronalaženje skrivenog znanja

Student: Anđela Spasić 3259/2025

Beograd, septembar 2026.

Sadržaj

1. Uvod....1
2. Zadatak 1 – Prikupljanje podataka....1
3. Zadatak 2 – Preprocesiranje i analiza podataka....2
4. Zadatak 3 – Vizuelizacija podataka....4
5. Zadatak 4 – Višestruka linearna regresija....5
6. Zadatak 5 – Klasterovanje....10
7. Zadatak 6 – Podsistem za preporučivanje....13
8. Zaključak i ograničenja....15

1. Uvod

U projektu su prikupljeni podaci o proizvodima bele tehnike sa dve srpske internet prodavnice, zatim su očišćeni, analizovani i prikazani grafički, a nad njima su samostalno napisana tri modela: predviđanje cene višestrukom linearnom regresijom, klasterovanje algoritmom K-srednjih vrednosti i preporučivanje sličnih proizvoda. Sva tri modela koriste se kroz aplikaciju sa prozorom. Poglavlja prate zadatke redom.

Tabela 1.1. – Pregled rezultata po celinama projekta

Celina	Rezultat
Preuzeto stranica	53.482 (winwin.rs i gigatron.rs)
Primarna baza	15.949 proizvoda
Prečišćena baza	11.984 proizvoda
Zapisa karakteristika (primarna baza)	300.688
Kategorija uređaja	38
Proizvođača	197
Predviđanje cene	$R^2 = 0,850$ (logaritamski prostor), medijana greške 21,4%
Klasterovanje (K-srednjih vrednosti)	Silhouette koeficijent = 0,407, frižideri, K = 4

2. Zadatak 1 – Prikupljanje podataka

Podaci su prikupljeni sa dve prodavnice, winwin.rs i gigatron.rs. Prodavnica winwin.rs drži kategoriju proizvoda u adresi stranice, pa se bela tehnika izdvaja pre preuzimanja, a gigatron.rs radi na drugoj platformi i traži drugu tehniku parsiranja.

Indekser adrese proizvoda ne traži praćenjem linkova, nego ih čita iz sitemap fajlova koje prodavnice objavljuju za pretraživače, pa se ceo katalog dobija bez obilaženja stranica kategorija. Svaka stranica se snima na disk (gzip), a parser radi samo nad snimljenim stranicama. Zato se prekinuto preuzimanje nastavlja tamo gde je stalo, a parser može da se menja i ponovo pokreće bez novih zahteva ka prodavnici. Prema sajtovima se poštuju sledeća pravila:

- Učitava se i poštuje robots.txt svake prodavnice, a zahtevi se šalju sa zaglavljima običnog pregledača.
- Između dva zahteva pravi se nasumična pauza, a paralelnih radnika je najviše pet.
- Neuspeo zahtev se ponavlja najviše tri puta, sa rastućom pauzom.
- Svaki zahtev se upisuje u dnevnik indeksiranja (adresa, status, trajanje).

Parser kombinuje više tehnika (tabela 2.1): DOM parser, koji čita stablo elemenata strane, meta oznake, regularne izraze i semantičke anotacije JSON-LD. Gigatron.rs ima dva rasporeda stranice: stariji, sa tabelom specifikacija u HTML-u, i noviji, u kome su specifikacije samo zapis u formatu JSON u izvornom kodu strane, pa se za svaki raspored koristi druga tehnika.

Tabela 2.1. – Tehnike parsiranja po prodavnici

Prodavnica	Platforma	Tehnika parsiranja	Šta se odatle čita
winwin.rs	Magento	DOM parser (tabela th/td, lista detalja, blok sa stanjem)	specifikacije, dostupnost na lageru
winwin.rs	Magento	meta oznake stranice	cena i valuta
winwin.rs	Magento	regularni izrazi nad JavaScript objektom (dataLayer)	šifra artikla, naziv, brend, kategorija
gigatron.rs	Next.js	semantičke anotacije (JSON-LD, schema.org)	naziv, brend, cena, ocene kupaca, kategorija
gigatron.rs	Next.js	DOM parser (tabela td/td)	specifikacije, stariji raspored
gigatron.rs	Next.js	regularni izrazi nad JSON zapisom	specifikacije, noviji raspored
gigatron.rs	Next.js	alt atribut slike	energetska klasa i skala

Tabela 2.2. – Broj proizvoda i karakteristika po prodavnici

Prodavnica	Proizvoda u primarnoj bazi	Karakteristika po proizvodu
winwin	9.634	20,8
gigatron	6.315	15,9

Podaci su preuzeti u intervalu od 31.08.2026. do 01.09.2026. Svi zapisi u primarnoj bazi preuzeti su u tom intervalu i svaki ima cenu, pa su aktuelni u trenutku preuzimanja; dostupnost na lageru čuva se kao posebno polje.

Broj zahteva se razlikuje po prodavnici. Sa winwin.rs je preuzeto samo 9.677 stranica bele tehnike, jer je kategorija u adresi. Gigatron.rs kategoriju u adresi nema, pa je zatraženo svih 43.874 stranica iz sitemapa, a bela tehnika (6.315 proizvoda) izdvojena je tek parsiranjem.

Primarna baza (PostgreSQL, baza psz_primarna) ima tabele prodavnice, proizvodi, karakteristike i dnevnik_indeksiranja. Tabela proizvodi čuva adresu, šifru artikla, naziv, brend, kategoriju, cenu, dostupnost na lageru i vreme preuzimanja, a izvor je veza sa tabelom prodavnice. Različite vrste uređaja imaju različite karakteristike, pa se one ne čuvaju kao fiksne kolone, nego kao parovi naziv–vrednost, tačno kako pišu na sajtu. Za podatak koga na sajtu nema ne postoji ni zapis, a u prečišćenoj bazi je to polje NULL. Šema i izvoz obe baze su priloženi.

3. Zadatak 2 – Preprocesiranje i analiza podataka

Prečišćeni podaci su u posebnoj bazi psz_preciscena. U njoj je svaki uređaj jedan red sa tipiziranim kolonama, a podatak koga u izvoru nema ostaje NULL. Tabela poreklo povezuje red sa zapisima primarne baze, a dnevnik_ciscenja beleži koliko je zapisa odbačeno u kom koraku. Čišćenje ima sledeće korake:

- **Kategorije.** Kategorije sa sajta svode se na kontrolisani rečnik, a kategorije pribora, rezervnih delova i potrošnog materijala izbacuju se. Kod zbirnih kategorija, kao što je „Kućni aparati“, vrsta uređaja čita se iz naziva proizvoda.
- **Pribor.** Pribor koji prodavnica drži među uređajima prepoznaje se po nazivu i odbacuje.
- **Brendovi.** Ista firma se u izvorima piše na više načina, pa je među zadržanim proizvodima 260 različitih zapisa svedeno na 197 proizvođača.
- **Tipiziranje.** Iz teksta se vade broj i jedinica mere, a jedinica se proverava, jer se isti podatak piše kao „12000 BTU“, „7 kg“ ili „300 l“. Vrednost van razumnog opsega ostaje prazna, a zapis sa cenom van opsega se odbacuje.
- **Spajanje duplikata.** Isti uređaj iz obe prodavnice, ili sa dva oglasa u istoj, postaje jedan red sa najnižom, najvišom i prosečnom cenom. Ključ je brend i oznaka modela; oglas sa gigatron.rs bez prave oznake modela spaja se sa oglasom sa winwin.rs po nazivu, a outlet oglas se ne spaja sa redovnim. Polja koja jedna prodavnica nema popunjavaju se iz druge. Gde se u nastavku koristi jedna cena, to je najniža cena među prodavnicama (kolona cena_min).
- **Nepotpuni zapisi.** Uređaj ulazi u prečišćenu bazu samo ako posle spajanja ima bar 3 popunjena tehnička polja.

- **Klasa i pokazatelji.** Energetska klasa i skala čuvaju se odvojeno (u nastavku), a računaju se i izvedeni pokazatelji: cena po inču dijagonale, po litru, po kilogramu kapaciteta i po kilovatu rashladnog učinka.

Tabela 3.1. – Dnevnik čišćenja: broj zapisa po koraku

Korak	Broj zapisa	Udeo
Učitano iz primarne baze	15.949	100,0%
Odbačeno: kategorija nije bela tehnika	212	1,3%
Odbačeno: cena van opsega	8	0,1%
Odbačeno: pribor po nazivu	108	0,7%
Odbačeno: premalo popunjenih karakteristika	2.198	13,8%
Spojenih zapisa u duplikate	1.439	9,0%
Upisano u prečišćenu bazu	11.984	75,1%

Udeo zadržanih zapisa je sličan po prodavnici: 85,9% sa winwin.rs i 81,6% sa gigatron.rs.

U izvorima postoje dve skale energetske klase: stara, sa plusevima (A+++ do D, kod nekih vrsta uređaja i niže), i nova (A do G), uvedena 2021. godine. Nova skala je strožija, a zvanično preslikavanje između njih ne postoji, pa se klasa i skala čuvaju odvojeno, a numerički rang se računa unutar sopstvene skale. Skalu određuje izričita oznaka („po prethodnoj klasifikaciji“ ili znak „+“ za staru, „Novo“ za novu), a za golo slovo skala se određuje po vrsti uređaja.

Uslov upita (c), klasa C ili A+ po staroj klasifikaciji ili bolja, time postaje jedan uslov: obe granice su treće odozgo na svojoj skali, pa je uslov „rang unutar skale najviše 3“. Takvih uređaja je 2.518.

Upiti su napisani u jeziku SQL i priloženi su zajedno sa rezultatima. Tabela 3.2 sažima odgovore na upite (a)–(e).

Tabela 3.2. – Rezultati upita

Upit	Rezultat
(a) Broj proizvoda po kategorijama	38 kategorija; najveće: Televizori (1.895), Frižideri (1.464), Veš-mašine (856), Usisivači (821); ceo spisak je u prilogu
(b) Najzastupljeniji brendovi (prvih deset)	Gorenje (1.384), Bosch (1.215), Beko (1.148), VOX (989), LG (844), Samsung (622), Philips (468), Candy (416), Miele (287), Hisense (273); zajedno 7.646 proizvoda (63,8%), isto kao na slici 4.2
(c) Energetska klasa C (ili A+ po staroj) ili bolja	2.518 od 7.343 proizvoda sa poznatom klasom i skalom (34,3%)
(d) Cena do 50.000 dinara	7.061 proizvoda (58,9%)
(e) 30 najskupljih televizora	najskuplji 3.779.999 RSD; prvih deset je u tabeli 3.3, a ceo spisak u prilogu

Tabela 3.3. – Deset najskupljih televizora

Brend	Naziv	Dijagonala	Cena
Samsung	Samsung Smart televizor QE98QN100BTXXH	98″	3.779.999 RSD
LG	LG Smart televizor O88ZX9LA	88″	3.499.999 RSD
Hisense	HISENSE 116UXQ Mini LED 4K Ultra HD	116″	2.499.999 RSD
TCL	TCL 115X955 Max QD Mini-LED 4K Ultra HD	115″	2.349.999 RSD
Samsung	Samsung Smart televizor QE98QN90DATXXH	98″	1.569.999 RSD
Samsung	QE85QN900BTXXH Smart TV SAMSUNG	85″	1.299.999 RSD
Samsung	SAMSUNG Smart TV QE98QN90AATXXH	98″	1.259.999 RSD
Samsung	SAMSUNG QE98QN90FAT Neo QLED 4K Ultra HD	98″	1.207.999 RSD
Samsung	Samsung Smart televizor QE85QN900DTXXH	85″	1.182.399 RSD
Sony	Sony Smart televizor XR98X90LAEP	98″	1.059.999 RSD

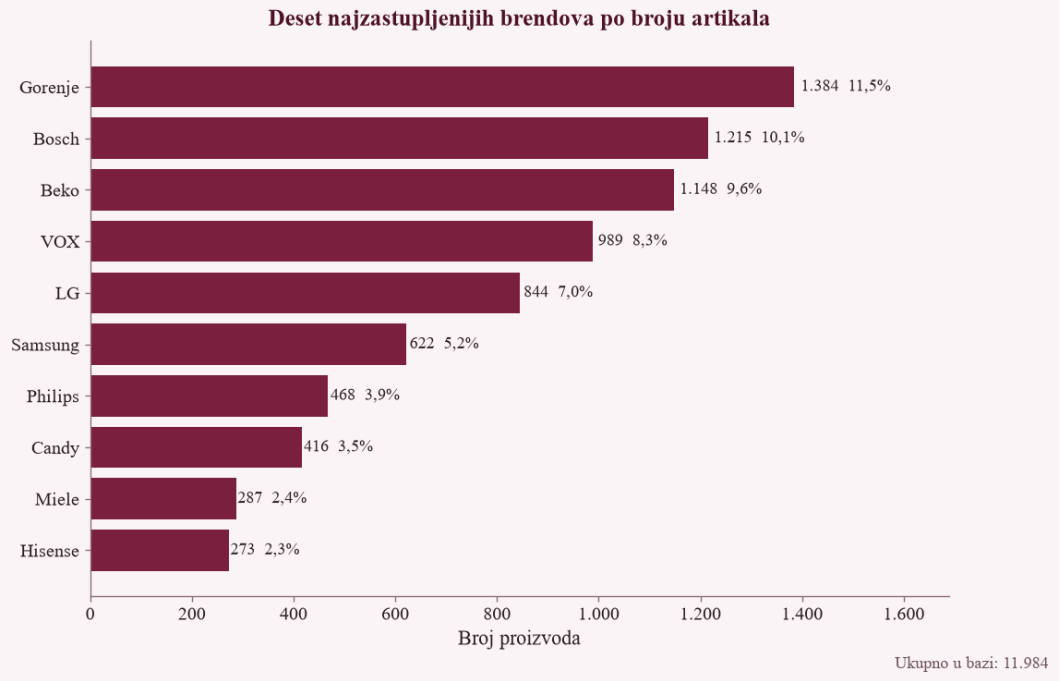
4. Zadatak 3 – Vizuelizacija podataka

Grafikoni su nacrtani iz prečišćene baze i snimljeni kao slike sa naslovom. Na slikama 4.1–4.4 ispisani su i broj i procenat proizvoda.



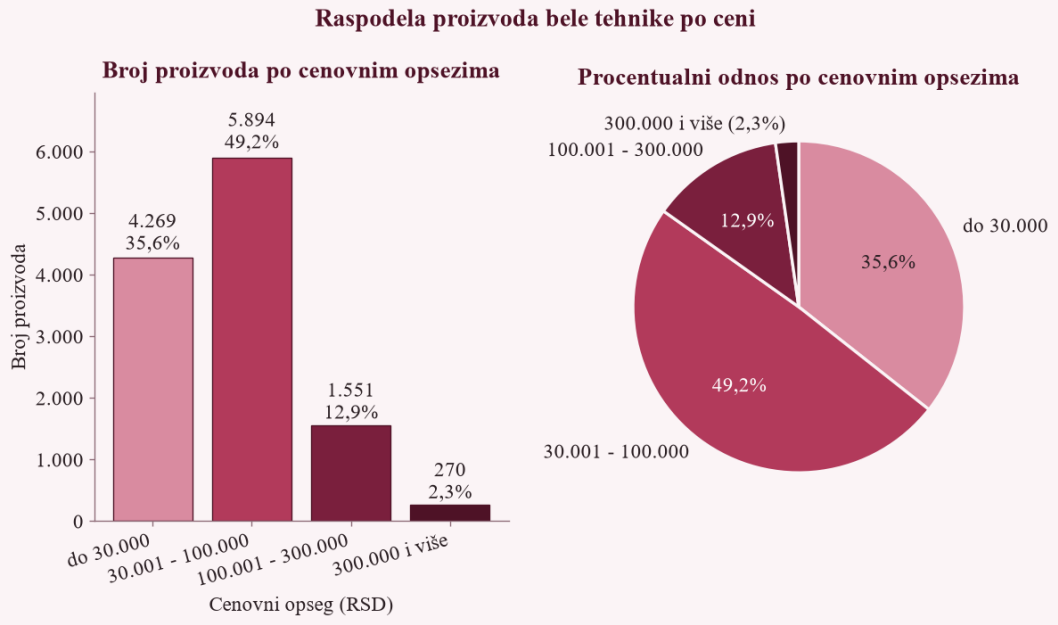
Slika 4.1. – Deset najzastupljenijih kategorija proizvoda

Na slici 4.1 prikazano je deset najzastupljenijih kategorija sa brojem i udelom proizvoda. Uočava se da su televizori i frižideri daleko najbrojniji i da zajedno čine 28,0% prečišćene baze, dok svaka od ostalih kategorija ima znatno manje proizvoda.



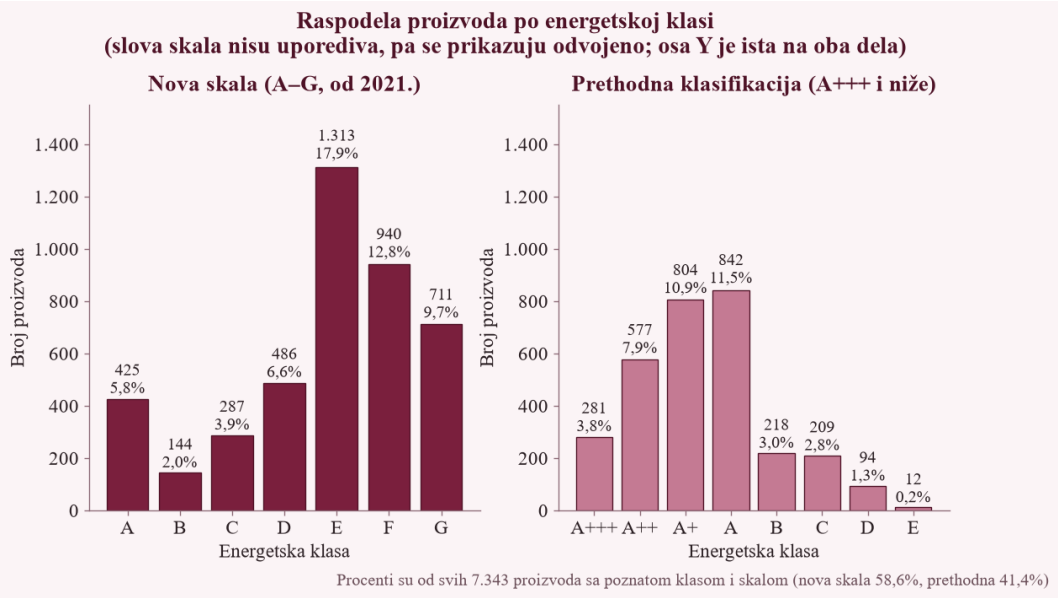
Slika 4.2. – Deset najzastupljenijih brendova po broju artikala

Na slici 4.2 prikazano je deset brendova sa najviše artikala. Uočava se da tih deset brendova pokriva 7.646 proizvoda, odnosno 63,8% baze, a najviše artikala imaju Gorenje, Bosch i Beko, što znači da je ponuda skoncentrisana kod nekoliko velikih proizvođača.



Slika 4.3. – Raspodela proizvoda po cenovnim opsezima (najniža cena među prodavnicama)

Na slici 4.3 prikazana je raspodela proizvoda po cenovnim opsezima. Uočava se da je najviše proizvoda u opsegu od 30.001 do 100.000 dinara (49,2%), u opsegu do 30.000 dinara je 35,6% proizvoda, od 100.001 do 300.000 dinara 12,9%, a od 300.000 dinara naviše svega 2,3%. Cena od tačno 300.000 dinara svrstana je u poslednji opseg, pa svaki proizvod pripada tačno jednom opsegu.



Slika 4.4. – Raspodela po energetskoj klasi, posebno za novu i za prethodnu skalu

Na slici 4.4 prikazan je broj i udeo proizvoda po energetskoj klasi, posebno za novu i za prethodnu skalu, jer klasa A na novoj i klasa A na staroj skali nisu isti nivo efikasnosti. Uočava se da na novoj skali preovlađuju klase E i F, a na prethodnoj klase A i A+. Procenti su računati među 7.343 proizvoda sa poznatom klasom i skalom; 4.641 proizvoda (38,7%) nema navedenu energetsku klasu.

5. Zadatak 4 – Višestruka linearna regresija

5.1. Model i priprema obeležja

Model predviđa najnižu cenu uređaja (cena_min) na osnovu kategorije i brenda (one-hot kodiranje: po jedna kolona sa vrednošću 0 ili 1 za svaku kategoriju i brend), energetskog ranga i numeričkih tehničkih

karakteristika. Funkcija troška, gradijent, korak gradijentnog spusta, predikcija i sve mere kvaliteta napisani su samostalno, a biblioteka numpy koristi se samo za rad sa nizovima:

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \ldots + \theta_n x_n$$

$$J(\theta) = (1/2m) \cdot \Sigma(\hat{y} - y)^2 + (\lambda/2m) \cdot \Sigma\theta_j^2 \qquad (j \geq 1)$$

$$\theta := \theta - (\alpha/m) \cdot [\, X^T(X\theta - y) + \lambda \cdot \theta' \,] \qquad (\theta'_0 = 0)$$

Numeričke kolone se standardizuju, a prazno polje se popunjava medijanom kategorije (ili svih proizvoda, ako kategorija tu karakteristiku nema), uz kolonu-pokazatelj da je vrednost nedostajala. Dve odluke najviše utiču na kvalitet modela:

- **Logaritam cene.** Cene se kreću od 699 do 3.779.999 dinara i raspodela im je jako iskošena, pa bi model nad sirovom cenom najviše pažnje davao najskupljim uređajima. Uz logaritam model uči odnose umesto razlika. Pod istim podešavanjima srednja apsolutna procentualna greška (MAPE) iznosi 74,8% sa sirovom, a 35,7% sa logaritmovanom cenom. Cena se u dinare vraća kao exp(Xθ), što je procena tipične (medijanske) cene uređaja takvih karakteristika.
- **Članovi interakcije.** Svaka numerička karakteristika množi se pokazivačem kategorije, pa model uči zaseban nagib po kategoriji: litar zapremine ne vredi isto kod frižidera i kod kuvala za vodu. Kolona se prvo standardizuje, pa množi, jer bi obrnut redosled dao ogromne vrednosti i spust bi divergirao. Pod istim podešavanjima model bez interakcija postiže R^2 (log) od 0,797 i medijanu greške 25,9%, a model sa interakcijama 0,826 i 23,5%.

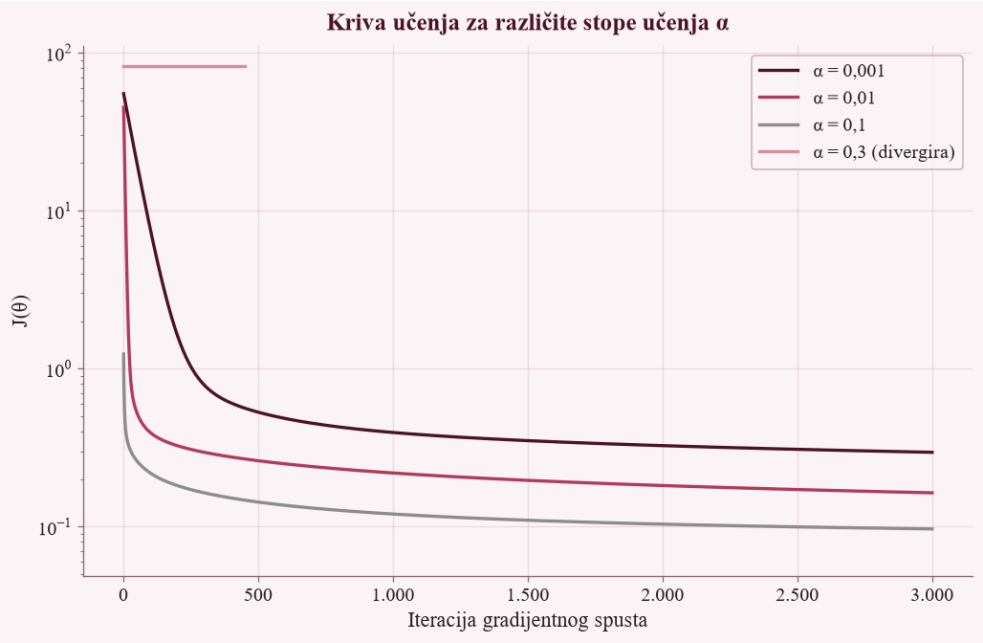
5.2. Eksperimenti

Podaci su podeljeni na skup za treniranje i skup za testiranje u odnosu 80:20 (seme 2026): 9.587 i 2.397 proizvoda. Menjani su stopa učenja α, broj iteracija, jačina L2 regularizacije λ, logaritam cene i članovi interakcije (tabela 5.1). Mere su na skupu za testiranje: R^2 (log) je koeficijent determinacije nad logaritmom cene, medijana i MAPE su medijana i prosek apsolutne procentualne greške, a RMSE je koren srednje kvadratne greške u dinarima.

Tabela 5.1. – Eksperimenti sa parametrima gradijentnog spusta

α	Iteracija	λ	log(cena)	Interakcije	R^2 (log)	Medijana	MAPE	RMSE (RSD)
0,001	3.000	0,0	da	da	0,5193	42,7%	70,9%	101.225
0,010	3.000	0,0	da	da	0,7266	31,2%	47,5%	69.946
0,100	3.000	0,0	da	da	0,8264	23,5%	35,7%	58.142
0,300	449	0,0	da	da	divergiralo	divergiralo	divergiralo	divergiralo
0,100	10.000	0,0	da	da	0,8437	22,0%	33,4%	59.551
0,100	3.000	1,0	da	da	0,8260	23,5%	35,8%	58.039
0,100	3.000	10,0	da	da	0,8228	23,9%	36,1%	57.373
0,100	3.000	0,0	ne	da	nedefinisano	38,2%	74,8%	60.100
0,100	3.000	0,0	da	ne	0,7966	25,9%	39,2%	63.676

Iz tabele se vidi: najveća isprobana stopa učenja pri kojoj spust ne divergira je 0,100; sa stopom 0,300 trošak divergira posle 449 iteracija, pa mere tog reda ne postoje; više iteracija popravlja model (sa 10.000 iteracija R^2 (log) je 0,8437 umesto 0,8264); regularizacija ne donosi poboljšanje, jer gradijentni spust koji polazi od nule i radi ograničen broj iteracija već deluje kao blaga regularizacija.



Slika 5.1. – Trošak kroz iteracije za četiri stope učenja iz tabele 5.1

Na slici 5.1 prikazan je trošak kroz iteracije za četiri stope učenja. Uočava se da sa manjom stopom trošak opada sporije, da stopa 0,1 najbrže stiže do niske vrednosti, a da sa prevelikom stopom trošak ne opada, nego spust divergira.

5.3. Konačni model i korisnička forma

Pošto R^2 (log) i dalje raste sa brojem iteracija, konačni model je obučen sa stopom učenja 0,1, bez regularizacije i sa 25.000 iteracija. Tabela 5.2 daje mere na oba skupa; MAE je srednja apsolutna greška.

Tabela 5.2. – Kvalitet konačnog modela na skupu za treniranje i testiranje

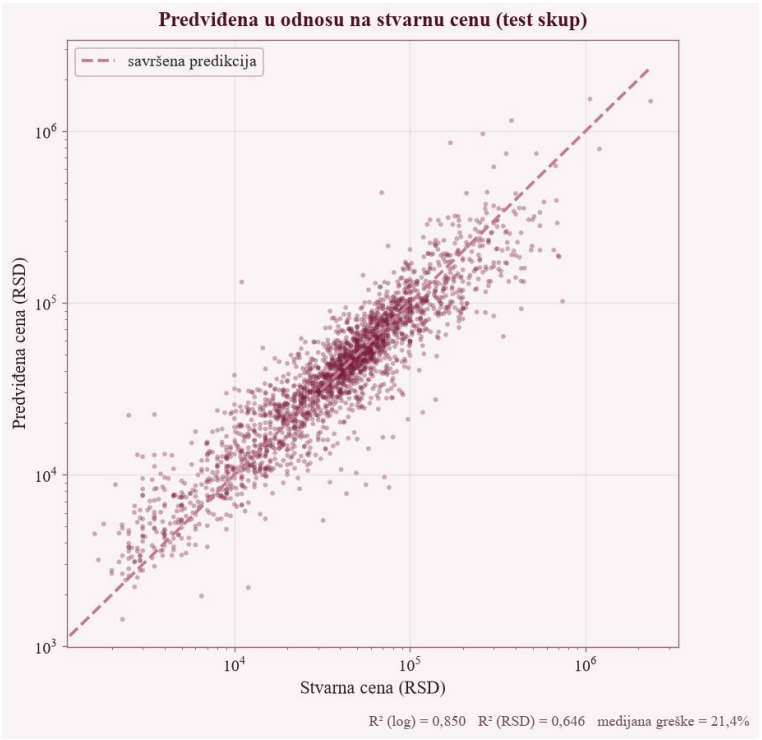
Mera	Skup za treniranje	Skup za testiranje
R^2 (logaritamski prostor)	0,8615	0,8502
R^2 (u dinarima)	0,6290	0,6462
RMSE	63.063 RSD	58.226 RSD
MAE	—	21.782 RSD
Srednja procentualna greška	—	32,6%
Medijana procentualne greške	—	21,4%

Mere na skupu za treniranje i testiranje su bliske, pa model nije preprilagođen. Model uči logaritam cene, pa mu je greška relativna: na polovini uređaja manja je od 21,4%. Ista relativna greška je u dinarima veća kod skupih uređaja, pa je R^2 u dinarima niži.



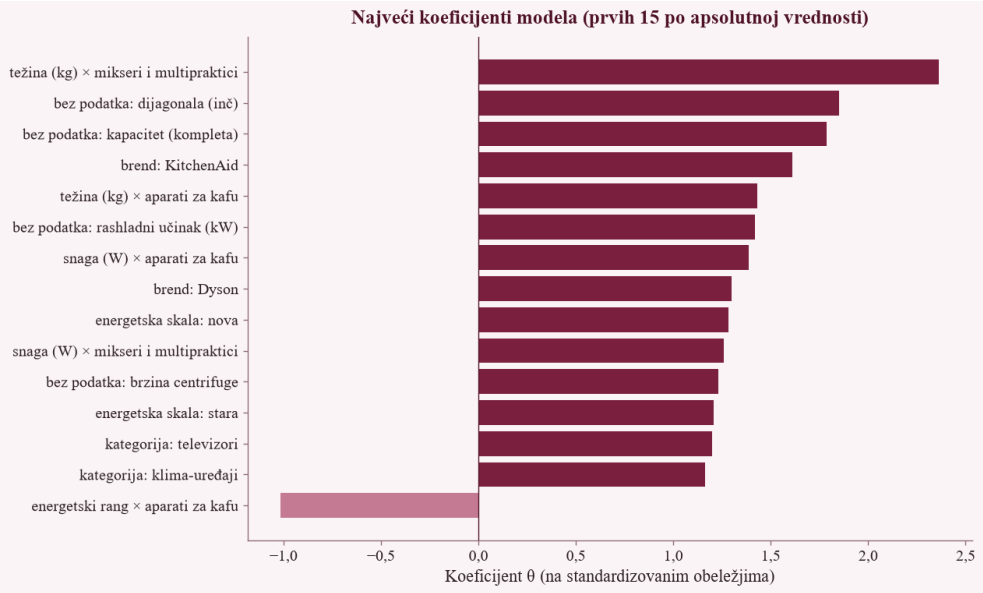
Slika 5.2. – Kriva učenja: vrednost funkcije troška kroz iteracije

Na slici 5.2 prikazana je kriva učenja konačnog modela. Uočava se da trošak naglo pada u prvim stotinama iteracija, a zatim sporo i bez oscilacija opada do kraja obučavanja, što pokazuje da je stopa učenja dobro izabrana.



Slika 5.3. – Predviđena u odnosu na stvarnu cenu; tačke prate dijagonalu kroz tri reda veličine

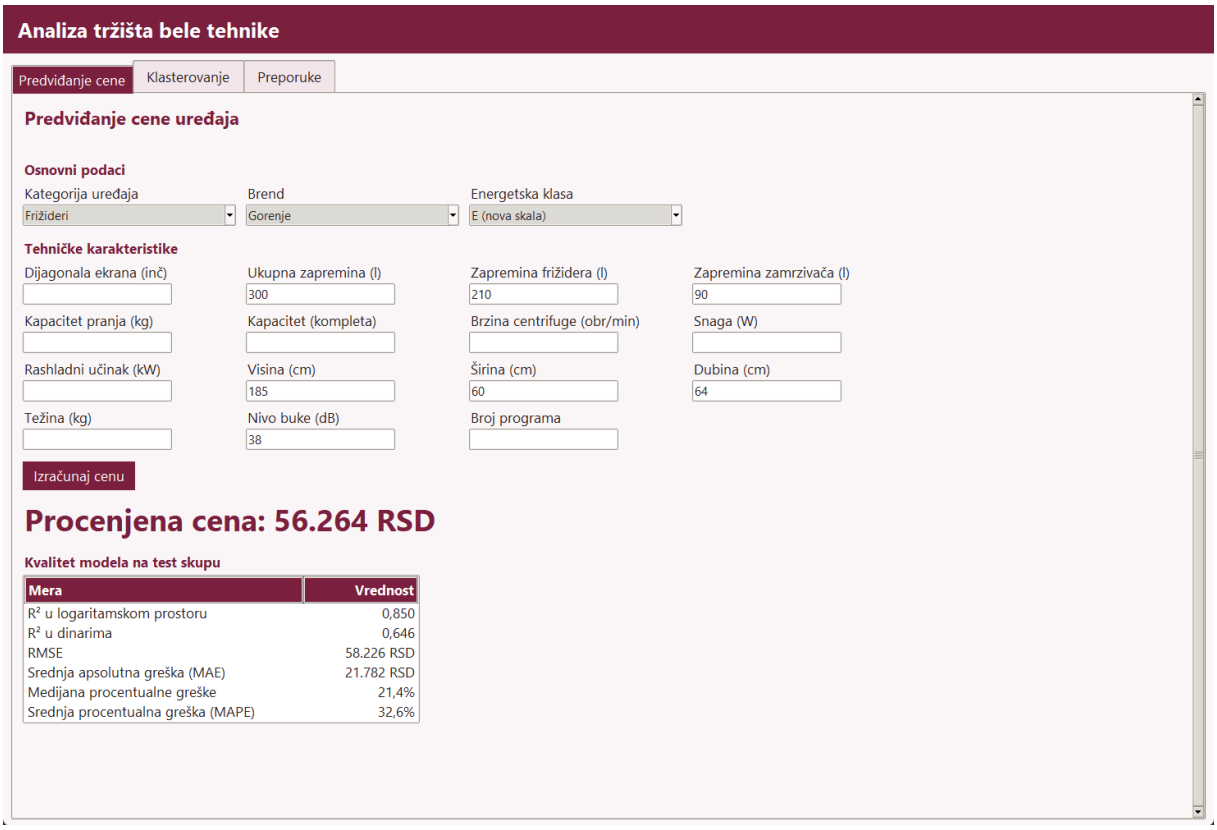
Na slici 5.3 prikazana je predviđena cena u odnosu na stvarnu na skupu za testiranje. Uočava se da tačke prate dijagonalu kroz tri reda veličine cene; ose su logaritamske, pa ista udaljenost tačke od dijagonale znači istu relativnu grešku, bez obzira na cenu uređaja.



Slika 5.4. – Najveći koeficijenti konačnog modela

Na slici 5.4 prikazani su najveći koeficijenti konačnog modela. Uočava se da su pri vrhu kategorije i pokazatelji nedostajućih vrednosti, koji u suštini razlikuju kategorije. Matrica obeležja je izrazito kolinearna, pa isto predviđanje daje mnogo različitih vektora koeficijenata; slika zato ne prikazuje jednoznačan uticaj svakog obeležja.

Model se koristi kroz formu u aplikaciji sa prozorom (slika 5.5): korisnik bira kategoriju, brend i energetsku klasu zajedno sa skalom i unosi karakteristike koje zna, a aplikacija ispisuje predviđenu cenu. Prazna polja popunjavaju se isto kao pri obučavanju, pa je procena pouzdana tek uz glavne karakteristike kategorije. Uneti broj mora biti između polovine najmanje i 1,5 puta najveće vrednosti te karakteristike u kategoriji, a umesto cene van raspona cena u bazi ispisuje se poruka o grešci.



Slika 5.5. – Forma za predviđanje cene sa izračunatim rezultatom

6. Zadatak 5 – Klasterovanje

6.1. Težine i pokretanje algoritma

Algoritam K-srednjih vrednosti (K-means) napisan je samostalno. Korisnik u interfejsu bira promenljive, težinski udeo svake od njih i broj klastera K. Promenljive se prvo standardizuju, jer bi se bez toga zapremina (stotine litara) i energetski rang (1 do 8) poredili na različitim skalama. Zatim se svaka množi korenom svoje težine, pa u kvadratu euklidskog rastojanja težina deluje tačno kao izabrani udeo:

$$d^2 = \Sigma\, w_j \cdot (x_j - c_j)^2 = \Sigma\, (\sqrt{w_j}\cdot x_j - \sqrt{w_j}\cdot c_j)^2$$

Težine se svode na zbir 100%: zbir veći od 100% forma odbija, a manji se srazmerno uvećava. Početni centri biraju se postupkom k-means++, u kome se svaki sledeći centar bira sa verovatnoćom srazmernom kvadratu rastojanja od već izabranih. Algoritam se pokreće deset puta, sa semenima od 2026 do 2035, i zadržava se rešenje sa najmanjom inercijom, odnosno sa najmanjim zbirom kvadrata rastojanja tačaka do centra svog klastera.

6.2. Izbor broja klastera

Inercija opada sa svakim novim klasterom, pa se uz nju računa i Silhouette koeficijent: s = (b − a) / max(a, b), gde je a prosečno rastojanje tačke do tačaka njenog klastera, a b do tačaka najbližeg drugog klastera. Vrednost blizu 1 znači jasno razdvojene grupe, a vrednost oko 0 tačke na granici.



Slika 6.1. – Metoda lakta i Silhouette koeficijent za frižidere, K od 2 do 10

Tabela 6.1. – Inercija i Silhouette koeficijent za frižidere

K	Inercija	Silhouette
2	635,3	0,495
3	467,3	0,325
4	339,7	0,407
5	271,3	0,371
6	231,8	0,367
7	201,3	0,372
8	179,1	0,341
9	163,0	0,345
10	148,1	0,328

Za svako K tabela i slika prikazuju najbolje od deset pokretanja. Najveći Silhouette daje K = 2 (0,495), ali dve grupe samo odvajaju velike i skupe frižidere od svih ostalih. Od K = 3 naviše najveći Silhouette ima K = 4 (0,407), pa je ta vrednost izabrana za primer. Kriva nema oštar lakat, ali se posle K = 4 osetno sporije spušta.

6.3. Rezultat

Primer su frižideri, K = 4, sa težinama: cena 50%, zapremina 30%, energetska klasa 20%. U analizu ulazi 1.112 frižidera kojima su poznate sve tri karakteristike. Cena ima najveću težinu, jer primer deli ponudu po cenovnim razredima, a energetska klasa najmanju, jer njen rang zavisi i od skale nalepnice. Tabela 6.2 daje broj proizvoda, prosečnu cenu i opis svakog klastera.

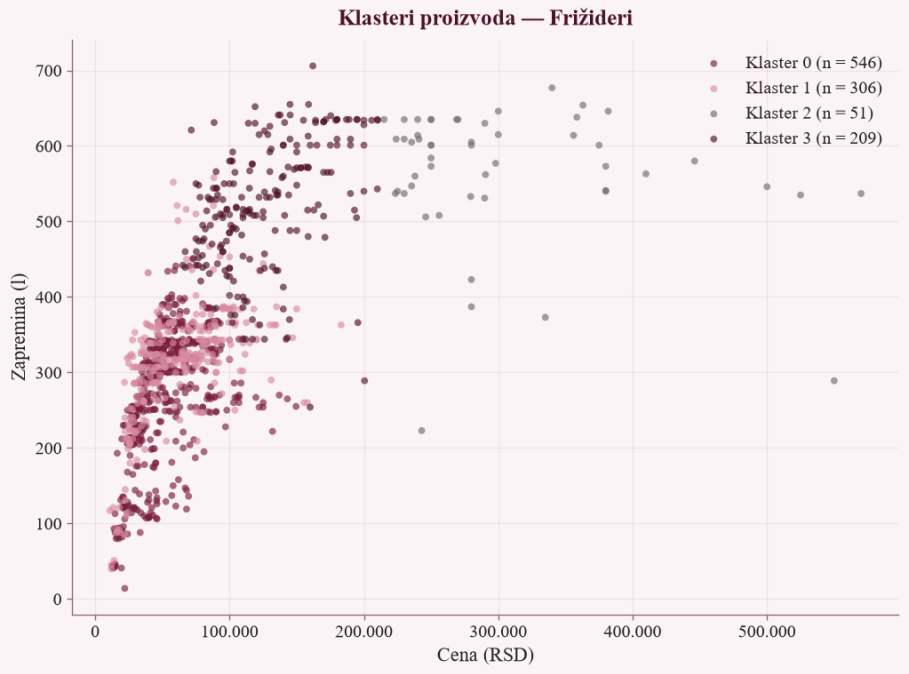
Tabela 6.2. – Klasteri frižidera

Klaster	Proizvoda	Udeo	Prosečna cena	Sa starom skalom	Opis
0	546	49,1%	50.370 RSD	4	jeftiniji uređaji, najčešće energetska klasa E po novoj skali
1	306	27,5%	61.924 RSD	231	uređaji srednje cene, mešane energetske skale, najčešće energetska klasa A+ po prethodnoj klasifikaciji
3	209	18,8%	126.471 RSD	20	skuplji uređaji, veća zapremina, najčešće energetska klasa E po novoj skali
2	51	4,6%	306.069 RSD	4	znatno skuplji uređaji, znatno veća zapremina, najčešće energetska klasa F po novoj skali

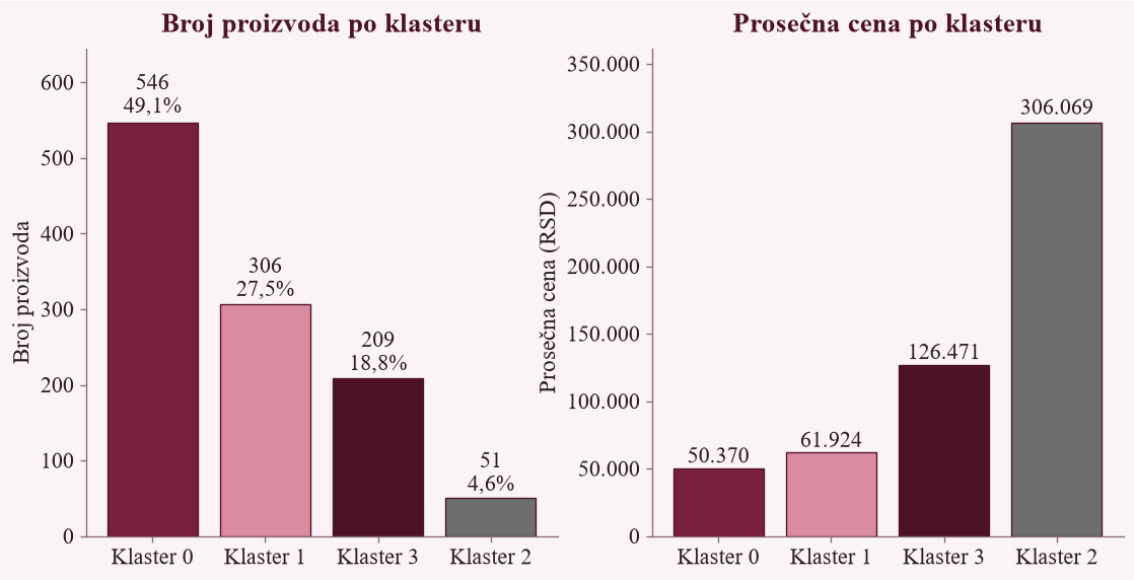
Najbolje od deset pokretanja ima inerciju 339,7 i zaustavilo se posle 14 iteracija, kada se dodela tačaka klasterima više nije menjala. Silhouette koeficijent iznosi 0,407, što po uobičajenoj podeli ukazuje na slabu strukturu: grupe se razlikuju, ali se na granicama preklapaju, jer cena i zapremina frižidera rastu postepeno, bez prirodnih skokova.

Klasteru 1 je po prosečnoj ceni najbliži klaster 0, a razdvaja ih pre svega skala energetske nalepnice: u klasteru 1 je 231 od 306 frižidera označeno starom skalom, a u klasteru 0 samo 4 od 546. Zato opis klastera klasu uvek navodi zajedno sa skalom.

Slika 6.2 prikazuje frižidere po ceni i zapremini, obojene po klasteru, a slika 6.3 broj proizvoda i prosečnu cenu po klasteru. Uočava se da se klasteriređaju po ceni i zapremini: najbrojniji klaster čine jeftiniji i manji frižideri, a najmanji klaster najskuplji i najveći.

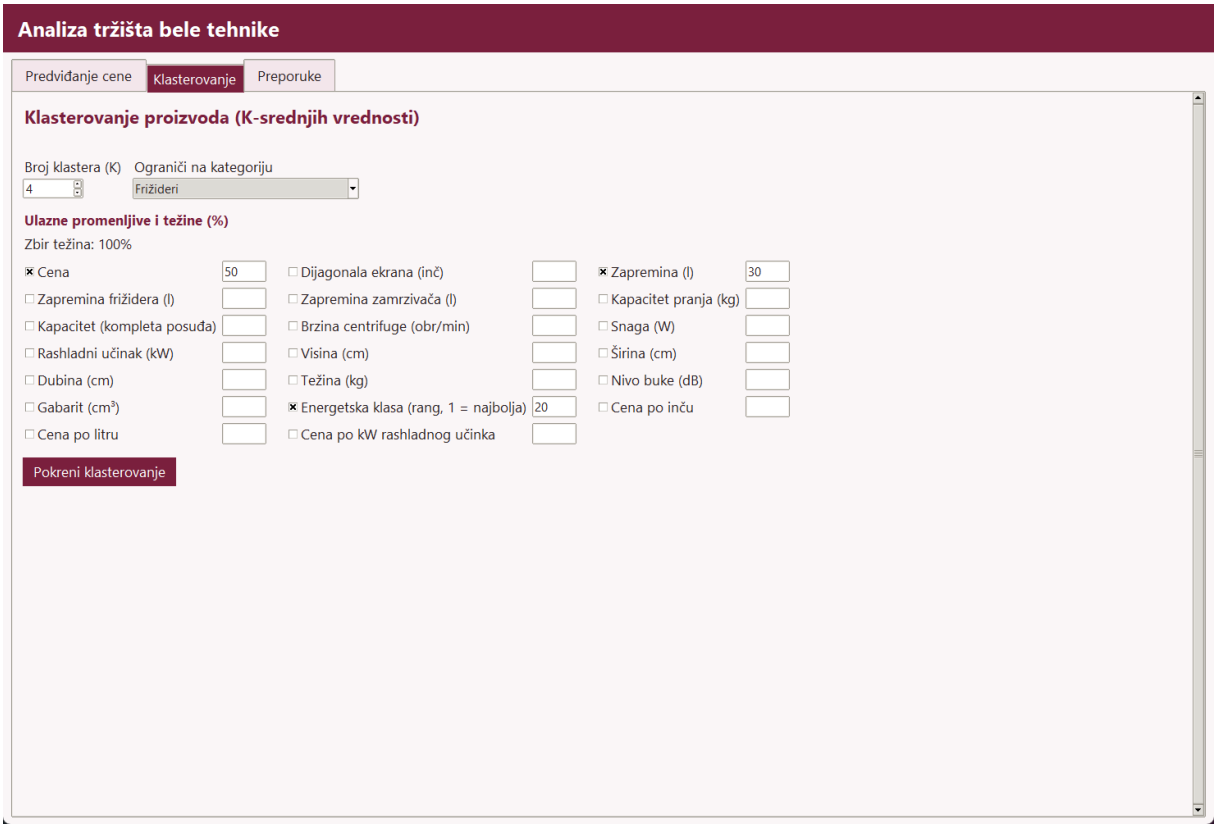


Slika 6.2. – Dijagram rasipanja, obojen po klasteru

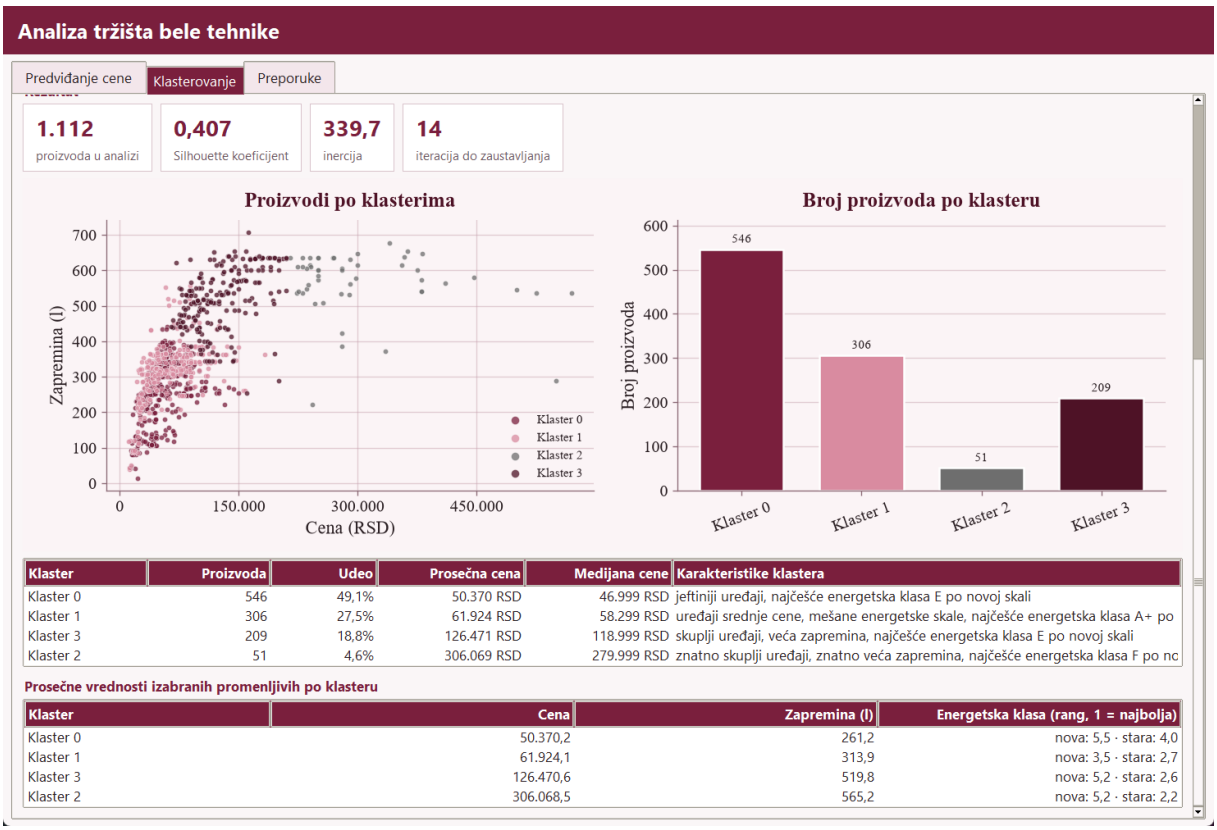


Slika 6.3. – Broj proizvoda i prosečna cena po klasteru

Na kartici za klasterovanje (slike 6.4 i 6.5) korisnik označava promenljive, upisuje njihove težine, pri čemu aplikacija odmah sabira težine i upozorava ako zbir pređe 100%, i bira broj klastera. Rezultat prikazuje broj proizvoda, prosečnu cenu, medijanu cene i opis svakog klastera, uz dijagram rasipanja i broj proizvoda po klasteru.



Slika 6.4. – Kartica za klasterovanje: izbor promenljivih, težina i broja klastera



Klaster	Proizvoda	Udeo	Prosečna cena	Medijana cene	Karakteristike klastera
Klaster 0	546	49,1%	50.370 RSD	46.999 RSD	jeftiniji uređaji, najčešće energetska klasa E po novoj skali
Klaster 1	306	27,5%	61.924 RSD	58.299 RSD	uređaji srednje cene, mešane energetske skale, najčešće energetska klasa A+ po
Klaster 3	209	18,8%	126.471 RSD	118.999 RSD	skuplji uređaji, veća zapremina, najčešće energetska klasa E po novoj skali
Klaster 2	51	4,6%	306.069 RSD	279.999 RSD	znatno skuplji uređaji, znatno veća zapremina, najčešće energetska klasa F po nc

Prosečne vrednosti izabranih promenljivih po klasteru

Klaster	Cena	Zapremina (l)	Energetska klasa (rang, 1 = najbolja)
Klaster 0	50.370,2	261,2	nova: 5,5 · stara: 4,0
Klaster 1	61.924,1	313,9	nova: 3,5 · stara: 2,7
Klaster 3	126.470,6	519,8	nova: 5,2 · stara: 2,6
Klaster 2	306.068,5	565,2	nova: 5,2 · stara: 2,2

Slika 6.5. – Kartica za klasterovanje: rezultat, grafikoni i opis klastera

7. Zadatak 6 – Podsistem za preporučivanje

7.1. Profil proizvoda

Preporuke su zasnovane na sadržaju: za izabrani proizvod sistem vraća pet najsličnijih proizvoda iz iste kategorije, poređanih od najsličnijeg ka najmanje sličnom. Profil proizvoda ima tri celine: numeričku (cena i tehničke karakteristike, standardizovane unutar kategorije), brend (one-hot kodiranje) i tekst (TF-IDF nad nazivom proizvoda). TF-IDF daje reči veću težinu kada je česta u nazivu, a retka u ostalim nazivima. U numeričku celinu ulaze karakteristike koje ima bar polovina proizvoda kategorije, a prazna polja se popunjavaju medijanom kategorije. Preporuke postoje za kategorije sa bar šest proizvoda. TF-IDF i kosinusna sličnost, uključujući skalarni proizvod i intenzitete vektora, napisani su samostalno:

```
tf(t,d)   = broj pojavljivanja reči t u nazivu d / ukupan broj reči u d
idf(t)    = ln( N / (1 + df(t)) ) + 1

cos(a,b)  = (a · b) / (‖a‖ · ‖b‖)
```

Isti uređaj se u listi ne ponavlja: prepoznaje se po brendu i skupu slova i cifara u nazivu, pa se izbacuje isti model iz dve prodavnice i isti model sa dva oglasa u istoj prodavnici.

7.2. Težine celina: cena ili brend

Svaka celina se svede na jediničnu dužinu i pomnoži korenom svoje težine, pa je kosinusna sličnost celog vektora tačno težinski prosek sličnosti po celinama:

$$\cos(A,B) = w_1 \cdot \cos_{\text{numeričko}}(A,B) + w_2 \cdot \cos_{\text{brend}}(A,B) + w_3 \cdot \cos_{\text{tekst}}(A,B)$$

Izabrane težine su: tehničke karakteristike i cena 60%, naziv 25% i brend 15%. Cilj je da se nađe zamena za uređaj, a ne isti proizvođač, pa brend nosi najmanju težinu. Naziv nosi podatke kojih u tabeli karakteristika nema, na primer „inverter“, „no frost“ ili „side by side“. Ime brenda se izbacuje iz naziva pre računanja TF-IDF-a, da brend ne bi ulazio u sličnost dva puta.

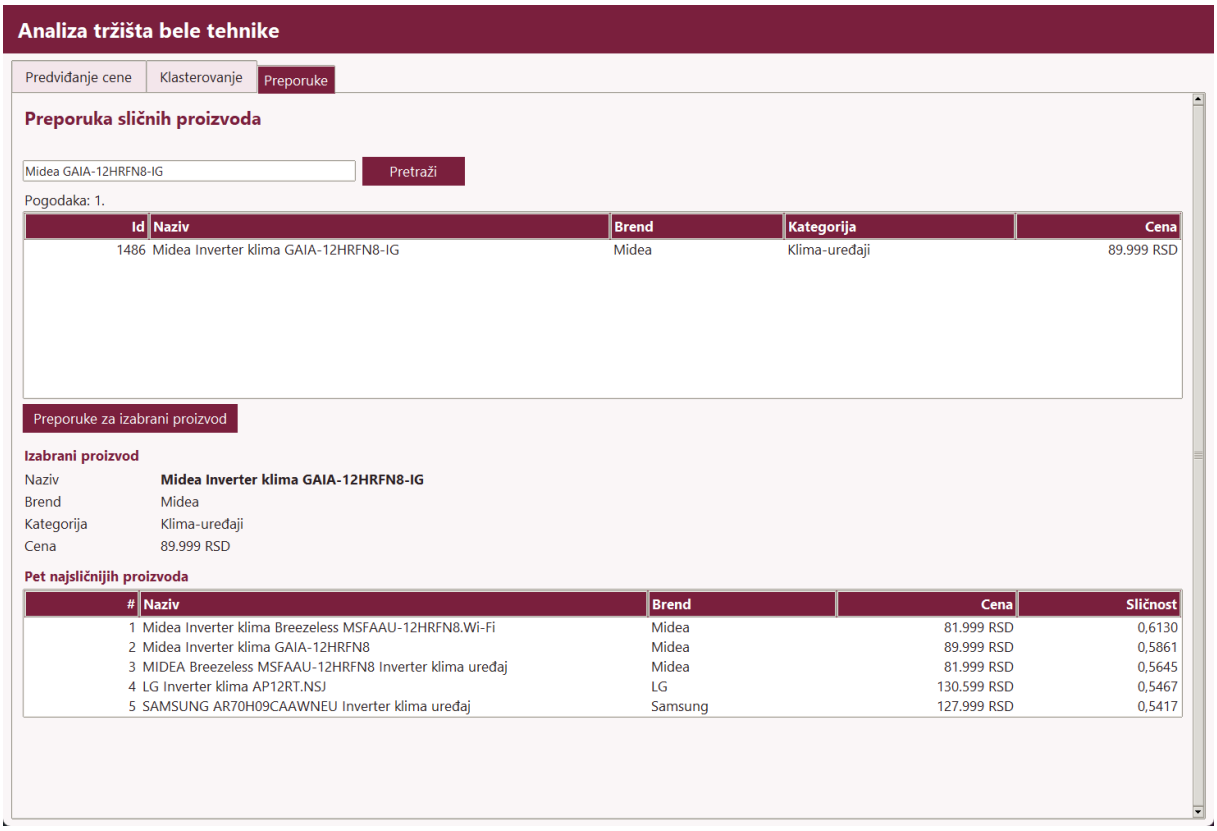
Cena utiče na preporuku manje od brenda. Cena je samo jedna od 10 karakteristika numeričke celine kod frižidera i jedna od 5 kod klima-uređaja, pa na nju otpada oko 6%, odnosno 12% sličnosti, dok isti brend

uvek donosi punih 15%. Merenje nad svim kategorijama to potvrđuje: u 82,4% preporuka brend je isti kao kod izabranog proizvoda, iako taj brend u proseku ima 11,3% proizvoda kategorije. Kada se brendu da težina nula (numeričke karakteristike 60%, naziv 40%), taj udeo pada na 50,7%, a kada se preporučuje samo po numeričkim karakteristikama na 40,1%, jer proizvođači imaju slične serije uređaja. Kod proizvođača sa mnogo sličnih modela, kao na slici 7.2, svih pet preporuka zato može biti istog brenda.

7.3. Primeri rada

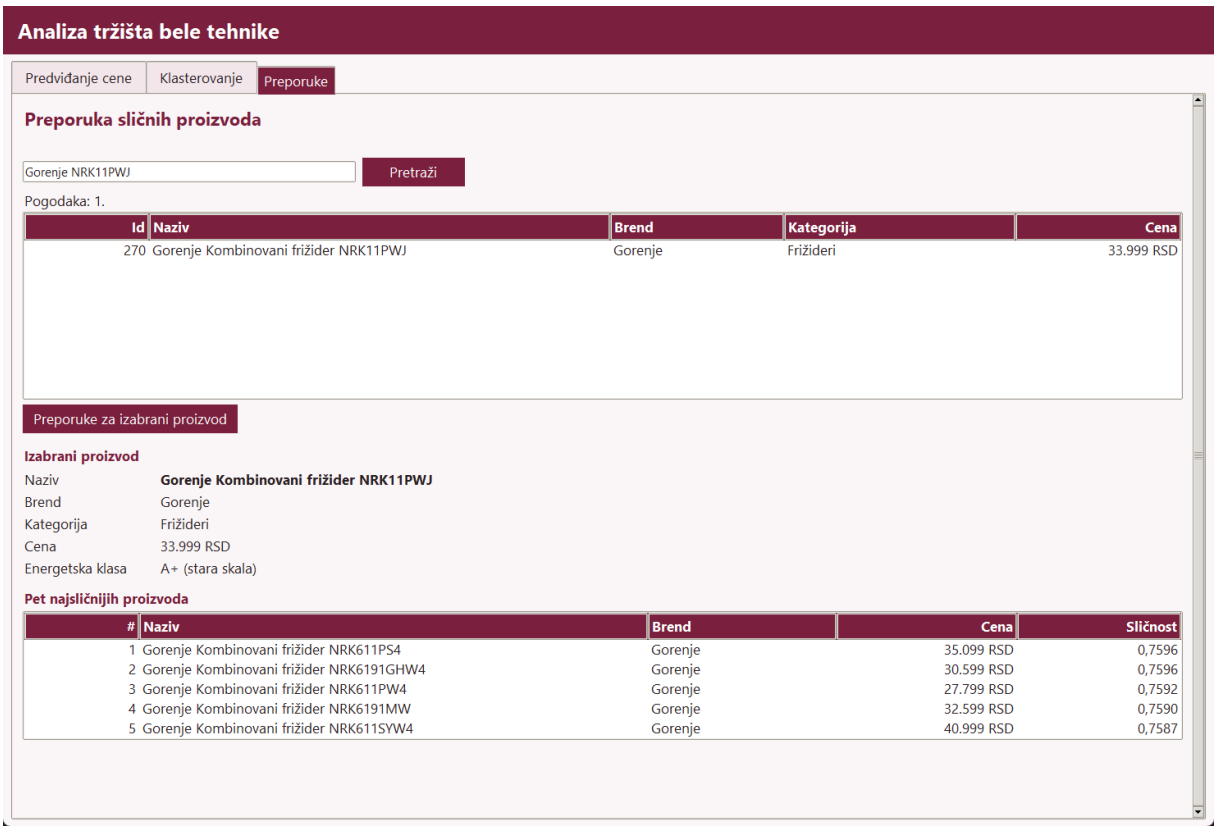
Primeri su napravljeni kroz aplikaciju.

Za uređaj Midea Inverter klima GAIA-12HRFN8-IG (id 1486, 89.999 RSD) sistem je preporučio pet modela iz iste kategorije, prikazanih na slici 7.1. Prve tri preporuke su Midea klime slične snage, a zatim LG i Samsung.



Slika 7.1. – Preporuke za uređaj Midea Inverter klima GAIA-12HRFN8-IG

Za uređaj Gorenje Kombinovani frižider NRK11PWJ (id 270, 33.999 RSD) sistem je preporučio pet modela iz iste kategorije, prikazanih na slici 7.2. Svih pet preporuka su Gorenje kombinovani frižideri iste zapremine odeljaka i dimenzija.



Slika 7.2. – Preporuke za uređaj Gorenje Kombinovani frižider NRK11PWJ

8. Zaključak i ograničenja

Prikupljeno je 15.949 zapisa o proizvodima bele tehnike sa dve internet prodavnice, a posle čišćenja i spajanja duplikata ostalo je 11.984 jedinstvena uređaja u 38 kategorija.

Model za predviđanje cene objašnjava 85,0% raspršenosti u logaritamskom prostoru i na polovini uređaja greši za manje od 21,4%. Klasterovanje frižidera odvaja velike i skupe uređaje od jeftinijih, uz Silhouette koeficijent 0,407 koji pokazuje da granice između grupa nisu oštre, a otkriva i da uređaje razdvaja skala energetske nalepnice, ne samo cena i zapremina. Podsistem za preporučivanje daje slične uređaje iz iste kategorije; brend pri tome utiče više nego što bi se po njegovoj težini od 15% očekivalo. Sve tri implementacije proverene su poređenjem sa bibliotekom scikit-learn i daju iste rezultate. Pri radu su primećena i sledeća ograničenja:

- Cene i dostupnost na lageru su presek stanja u trenutku preuzimanja, a dve prodavnice ne predstavljaju celo tržište Srbije.
- Kategorija i brend preuzimaju se onako kako ih sajt navodi, pa je primećeno da poneki proizvod stoji pod pogrešnom kategorijom ili brendom.
- Parametri gradijentnog spusta birani su na istom skupu za testiranje na kome se prijavljuje konačni rezultat, jer posebnog skupa za validaciju nema, pa je konačna procena blago optimistična.
- Greška modela nije ista po kategorijama: u dinarima je najveća kod najskupljih uređaja, a relativno najveća kod uređaja čija cena malo zavisi od karakteristika koje se mogu pročitati sa sajta.
- Stara i nova energetska skala nisu svedene na zajedničku meru, jer zvanično preslikavanje ne postoji. Zato energetski rang u klasterovanju i u preporukama delom razdvaja uređaje po skali nalepnice, a ne samo po efikasnosti.
- K-srednjih vrednosti nalazi lokalni minimum i osetljiv je na izuzetke, pa nekoliko najskupljih uređaja može da čini poseban klaster.
- Isti uređaj iz dve prodavnice ne prepozna se uvek kada se oznake modela razlikuju, pa je primećeno da poneki uređaj ostaje u dva reda.
- Kod klima-uređaja se čita opšta klasa ili klasa hlađenja, a ne klasa grejanja, pa mali broj njih ostaje bez klase.

- Isti prag od tri tehnička polja ne pogađa sve vrste uređaja jednako, jer izvori nekima navode uglavnom opisna polja.

Evaluacija pokazuje da su sva tri modela upotrebljiva na stvarnim podacima: model cene daje pouzdanu procenu za tipične uređaje, a najviše greši kod najskupljih i kod uređaja čija cena zavisi od osobina kojih na sajtu nema; klasterovanje otkriva cenovne razrede i razliku između dve skale energetske nalepnice; preporuke vraćaju uređaje istih karakteristika, najčešće iz iste serije proizvođača. Sva tri modela napisana su bez gotovih bibliotečkih rešenja, a rezultati su ponovljivi iz priloženog koda i baza. Navedena ograničenja su ujedno i pravci za dalji rad: bolje prepoznavanje istog uređaja u različitim prodavnicama, zajednička mera za dve energetske skale i poseban validacioni skup pri izboru parametara modela.